**ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH**
**TRƯỜNG ĐẠI HỌC BÁCH KHOA**
**KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH**

**ĐỒ ÁN TỔNG HỢP - HƯỚNG TRÍ TUỆ NHÂN TẠO**

# BÁO CÁO

---

**GVHD:** **Ths.Vương Bá Thịnh**
**Sinh viên thực hiện:** **Nguyễn Cảnh Nguyên**
**MSSV:** **2312357**

TP. HỒ CHÍ MINH, THÁNG 12 NĂM 2025

# Mục lục

**1 Tóm tắt nội dung** **2**

**2 Giới thiệu** **2**
2.1 Bối cảnh . . . . . 2
2.2 Vấn đề . . . . . 3
2.3 Mục tiêu của bài báo cáo . . . . . 3
2.4 Giới hạn của báo cáo . . . . . 3

**3 Cơ sở lý thuyết** **3**
3.1 Cơ chế chung (Stable Diffusion) . . . . . 3
3.1.1 Không gian tiềm ẩn (Latent space) . . . . . 3
3.1.2 Quá trình khuếch tán và khử nhiễu . . . . . 4
3.1.3 Text Conditioning . . . . . 5
3.2 Sự khác biệt giữa ba hướng tiếp cận . . . . . 5

**4 Phương pháp nghiên cứu đã tìm hiểu** **6**
4.1 Reward Backpropagation(Align Prop)) . . . . . 6
4.1.1 Vấn đề và ý tưởng của AlignProp . . . . . 6
4.1.2 Cách hiện thực AlignProp . . . . . 6
4.2 RealignDiff . . . . . 8
4.2.1 Vấn đề và ý tưởng của RealignDiff . . . . . 8
4.2.2 Căn chỉnh thô (Coarse Semantic Re-alignment) . . . . . 9
4.2.3 Căn chỉnh tinh (Fine Semantic Re-alignment) . . . . . 10
4.3 CoMat . . . . . 12
4.3.1 Vấn đề và ý tưởng của Comat . . . . . 12
4.3.2 Concept Activation . . . . . 13
4.3.3 Attribute Concentration . . . . . 15

**5 So sánh và thảo luận** **16**
5.1 Kết Quả Trực Quan . . . . . 18

**6 Hướng đi đề xuất từ 3 giải pháp trên** **19**

**7 Kết luận** **20**

# 1 Tóm tắt nội dung

Các mô hình sinh ảnh từ văn bản (T2I model) dựa trên cơ chế diffusion (khuếch tán nhiễu - khử nhiễu) đã đạt nhiều bước tiến quan trọng trong những năm gần đây. Tuy vậy, chúng vẫn gặp hạn chế về mức độ khớp của prompt so với ảnh, nguyên nhân chủ yếu đến từ việc mô hình chưa được tối ưu cho việc tăng độ khớp input prompt và ảnh, dẫn đến ảnh sinh ra bị thiếu các thực thể chính từ input prompt hoặc việc ánh xạ của thực thể chính và thuộc tính của nó chưa được chính xác. Báo cáo này tập trung khảo sát ba phương pháp bao gồm: CoMat (concept matching), RealignDiff (coarse-to-fine semantic re-alignment) và Reward Backpropagation (tối ưu hóa dựa trên gradient từ reward). Tôi phân tích cách mỗi phương pháp trên cải thiện độ khớp ảnh và prompt, đồng thời trình bày các methods của từng phương pháp cũng như các kết quả trực quan, đánh giá của tôi và đề xuất các hướng phát triển để giải quyết bài toán cải thiện độ khớp của ảnh so với prompt.

# 2 Giới thiệu

## 2.1 Bối cảnh

Các mô hình sinh ảnh từ văn bản (Text-to-Image,T2I) dựa trên cơ chế diffusion đã đạt nhiều bước tiến trong việc tạo ra hình ảnh chất lượng cao và đa dạng dựa trên prompt. Tuy nhiên, khi đối mặt với các prompt phức tạp, các mô hình này vẫn gặp khó khăn trong việc khớp đúng mọi concept và thuộc tính của prompt. Ví dụ ở hình ở dưới (ảnh được lấy từ website SDXL online), mô hình hiện đại bậc nhất SDXL đã thất bại trong việc tạo thực thể và thuộc tính được yêu cầu ở trong prompts, ví dụ như việc nó đã sinh ảnh sai với yêu cầu như lông cú không làm từ ren, mắt cú không phát sáng như ngôi sao và xung quanh cũng không phải là đom đóm.

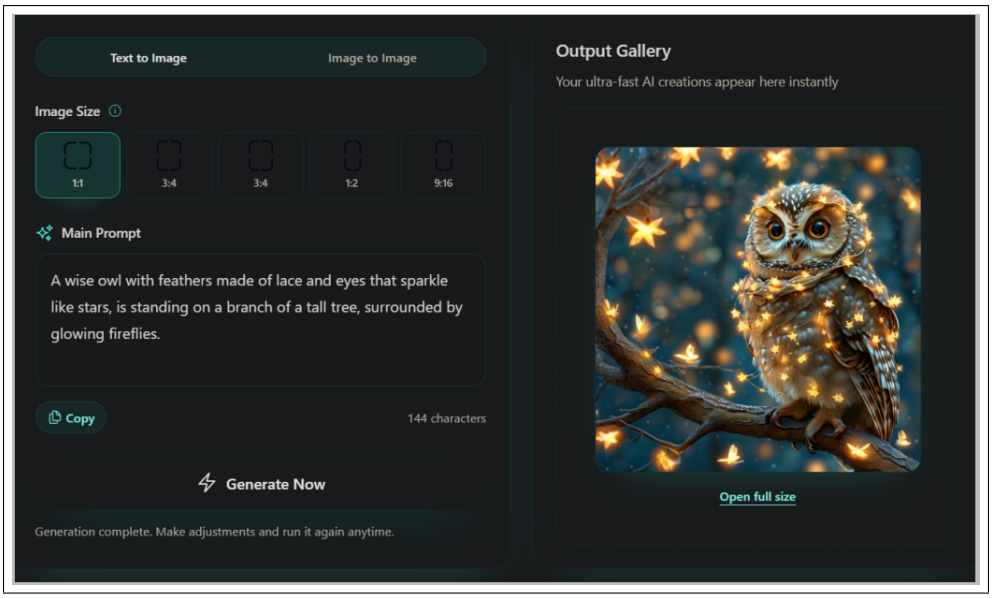


Hình 1: với prompt “A wise owl with feathers made of lace and eyes that sparkle like stars, is standing on a branch of a tall tree, surrounded by glowing fireflies” tạo ảnh trên web “https://stable-diffusion-web.com/sdxl”.

## 2.2 Vấn đề

Nguyên nhân chính của hiện tượng này là do mô hình không được tối ưu cho độ khớp ngữ nghĩa. Có nhiều cách để nhìn nhận vấn đề này, một trong những cách đó là: việc quên toàn cục - mô hình bỏ soát khái niệm trong input prompt và quên cục bộ - mô hình ánh xạ sai các chi tiết của các thực thể. Kết quả là mô hình sinh ảnh không khớp với prompt - vấn đề được quan tâm của bài báo cáo này.

## 2.3 Mục tiêu của bài báo cáo

Bài báo cáo này cung cấp phân tích chi tiết về 3 phương pháp để giải quyết vấn đề này (CoMat, RealignDiff và Reward Backpropagation). Ngoài ra còn trình bày tác động của từng phương pháp cũng như trình bày các kết quả trực quan, đánh giá từ cá nhân tôi và đưa ra hướng giải quyết của bài toán từ cá nhân tôi.

## 2.4 Giới hạn của báo cáo

Báo cáo chủ yếu tập trung vào phân tích lý thuyết và cơ chế phương pháp, chưa thực hiện thực nghiệm hoặc huấn luyện mô hình do hạn chế về tài nguyên tính toán và thời gian cũng như là kiến thức.

# 3 Cơ sở lý thuyết

## 3.1 Cơ chế chung (Stable Diffusion)

Cả ba bài báo đều dựa trên mô hình Stable Diffusion để làm model gốc để từ đó cải tiến hoặc hiện thực các giải pháp của họ. Stable Diffusion là một LDM (Latent Diffusion Model) là một model sinh ảnh dựa trên cơ chế khuếch tán và khử nhiễu, nhưng hoạt động trên không gian latent (không gian nén) thay vì không gian ảnh gốc để giảm thiểu số pixel phải xử lý, nhằm giảm chi phí tính toán và tăng hiệu quả học. Cơ chế chung của Stable Diffusion có thể tóm tắt như sau:

### 3.1.1 Không gian tiềm ẩn (Latent space)

Đầu tiên ảnh gốc $x_0$ (thường có chiều là 512x512x3) được mã hóa vào latent space thành $z_0$ (số chiều là 64x64x4) thông qua variational autoenconder (VAE):

$$z_0 = E(x_0), \quad x_0 \approx D(z_0) \tag{1}$$

Trong đó:

- $E$: Encoder nén ảnh xuống không gian latent thấp chiều.
- $D$: Decoder tái tạo ảnh từ latent space.
- $z_0$: giữ hầu hết thông tin quan trọng về cấu trúc và màu sắc, nhưng giảm đáng kể chi phí tính toán thay vì phải làm việc trên không gian ảnh.

### 3.1.2 Quá trình khuếch tán và khử nhiễu

**1. Quá trình khuếch tán thuận (Forward Diffusion):** Quá trình khuếch tán thuận là việc chúng ta thêm nhiễu Gaussian theo từng bước thời gian. Tại mỗi bước $t$, trạng thái tiềm ẩn $z_{t-1}$ được chuyển sang $z_t$ thông qua phân phối:

$$q(z_t|z_{t-1}) = \mathcal{N}(z_t; \sqrt{1-\beta_t} z_{t-1}, \beta_t \mathbf{I}), \tag{2}$$

trong đó công thức này đảm bảo rằng một phần thông tin của trạng thái trước được giữ lại, đồng thời bổ sung một lượng nhiễu có kiểm soát không làm cho phương sai bị bùng nổ sau nhiều bước thêm nhiễu.

Nhờ tính chất của phân phối Gaussian, trạng thái $z_t$ tại thời điểm bất kỳ có thể được lấy mẫu trực tiếp từ $z_0$ mà không cần thực hiện tuần tự toàn bộ quá trình Markov:

$$z_t = \sqrt{\bar{\alpha}_t} z_0 + \sqrt{1-\bar{\alpha}_t}\epsilon, \quad \epsilon \sim \mathcal{N}(0,1), \tag{3}$$

công thức này được sử dụng để tạo mẫu dữ liệu nhiễu tại bước $t$ trong quá trình huấn luyện mô hình diffusion.

**Chú thích các biến số:**

- $z_t$: Trạng thái tiềm ẩn của dữ liệu tại bước thời gian $t$.
- $\beta_t \in (0,1)$: Hệ số phương sai, điều khiển lượng nhiễu được thêm vào tại bước $t$.
- $\alpha_t = 1 - \beta_t$: Hệ số bảo toàn thông tin tại bước $t$.
- $\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$: Hệ số bảo toàn tích lũy sau $t$ bước khuếch tán.
- $\epsilon$: Nhiễu Gaussian chuẩn, giúp mô hình học cách khử nhiễu

**2. Quá trình khuếch tán ngược (Backward Diffusion)** Mục tiêu của mô hình là học cách đảo ngược quá trình trên để khôi phục $z_0$ từ nhiễu. Stable Diffusion sử dụng mạng thần kinh $U$-Net, ký hiệu là $\epsilon_\theta$, để dự đoán thành phần nhiễu $\epsilon$ đã được thêm vào tại mỗi bước:

$$\epsilon_\theta(z_t, t, c) \approx \epsilon \tag{4}$$

**Giải thích các biến số:**

- $t$: Thời gian.
- $c$: Conditioning từ văn bản, giúp điều hướng quá trình khử nhiễu.

**3. Hàm mất mát (Loss Function)** Để tối ưu hóa mạng $U$-Net, mô hình tối tiểu hóa sai số giữa nhiễu thực tế $\epsilon$ và nhiễu dự đoán $\epsilon_\theta$. Hàm mất mát được định nghĩa dưới dạng $L_{simple}$:

$$\mathcal{L}_{simple} = \mathbb{E}_{z_0,\epsilon,t,c}\left[\|\epsilon - \epsilon_\theta(z_t, t, c)\|^2\right] \tag{5}$$

Việc tối thiểu hóa loss này cho phép mô hình làm quen được cách khử nhiễu. Khi quá trình huấn luyện hoàn tất, ta có thể thực hiện tạo ảnh bắt đầu từ một nhiễu ngẫu nhiên $z_T$, sau đó khử nhiễu tuần tự qua $T$ bước để thu được $z_0$ sạch trước khi đưa qua bộ giải mã VAE Decoder để tạo ra hình ảnh cuối cùng.

### 3.1.3 Text Conditioning

Trong Stable Diffusion, prompt đầu vào được sử dụng để điều hướng quá trình sinh ảnh nhằm đảm bảo sự khớp giữa nội dung ảnh và nội dung của mô tả ngôn ngữ tự nhiên. Cụ thể, prompt văn bản được mã hóa thành embedding thông qua bộ mã hóa văn bản:

$$c = \text{TextEncoder}(\text{prompt}), \tag{6}$$

trong đó $c$ là biểu diễn ngữ nghĩa của văn bản, thường được trích xuất từ CLIP Text Encoder.

Embedding văn bản $c$ được tích hợp vào quá trình khử nhiễu của mô hình diffusion thông qua cơ chế cross-attention trong kiến trúc U-Net. Cơ chế attention được định nghĩa như sau:

$$\text{Attention}(Q, K) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right), \tag{7}$$

trong đó phép attention cho phép mô hình tính toán mức độ liên quan giữa các đặc trưng ảnh và các token văn bản.

Trong đó hàm attention được sử dụng để đo mức độ liên quan giữa đặc trưng ảnh tại bước khử nhiễu $t$ và embedding văn bản, từ đó điều hướng quá trình sinh ảnh theo nội dung của prompt.

**Chú thích các biến số:**

- $Q$ (Query): vector truy vấn được trích xuất từ feature map của latent $z_t$ trong U-Net, nó nghĩa là mỗi pixel nên ở đâu và chú ý từ nào.
- $K$ (Key): vector khóa được trích xuất từ embedding văn bản $c$, nó đại diện cho các token của prompt.
- $d$: chiều không gian của các vector thuộc tính.

Cơ chế cross-attention cho phép mỗi vị trí không gian trong latent ảnh tập trung vào các token văn bản khác nhau, qua đó tăng cường khả năng liên kết giữa văn bản và hình ảnh (text–image alignment).

## 3.2 Sự khác biệt giữa ba hướng tiếp cận

Mặc dù đều dựa trên mô hình nền tảng **Stable Diffusion**, ba phương pháp **AlignProp**, **RealignDiff** và **CoMat** thể hiện những hướng tiếp cận khác nhau trong việc cải thiện mức độ khớp ngữ nghĩa giữa ảnh sinh ra và prompt văn bản. Sự khác biệt này đến từ cách mỗi phương pháp định nghĩa mục tiêu tối ưu và cách đưa tín hiệu ngữ nghĩa quay trở lại mô hình.

- **AlignProp** là hướng tiếp cận sớm, tập trung vào việc mở rộng mục tiêu huấn luyện của diffusion model. Thay vì chỉ tối ưu sai số khử nhiễu truyền thống, AlignProp xem toàn bộ quá trình sinh ảnh như một chuỗi biến đổi khả vi và cho phép lan truyền gradient trực tiếp từ một hàm reward đánh giá ảnh đầu ra.
- **RealignDiff** tiếp cận bài toán tăng độ khớp prompt-ảnh ở mức trung gian hơn, bằng cách bổ sung cơ chế phản hồi ngữ nghĩa trong quá trình huấn luyện. Phương pháp này khai thác thông tin từ ảnh sinh ra để tái căn chỉnh mối quan hệ giữa văn bản và hình ảnh theo chiến lược từ thô đến tinh (*coarse-to-fine*). Nhờ đó, RealignDiff không chỉ đảm bảo nội dung trên toàn cục đối với input prompt mà còn giảm bớt các sai lệch cục bộ.

- **CoMat** đại diện cho hướng tiếp cận chi tiết nhất và theo tôi là hay nhất, tập trung trực tiếp vào cơ chế **cross-attention** trong U-Net, nơi diễn ra sự tương tác giữa token văn bản và đặc trưng không gian của ảnh. Thay vì chỉ đánh giá ảnh đầu ra, CoMat giám sát và điều chỉnh cách từng khái niệm và thuộc tính trong prompt được kích hoạt và ánh xạ vào các vùng ảnh tương ứng, nhằm giải quyết trực tiếp các hiện tượng bỏ sót khái niệm và gán nhầm thuộc tính.

Tuy khác nhau về cách tiếp cận, cả ba hướng đều cùng hướng tới mục tiêu chung là **cải thiện mức độ phù hợp giữa ảnh sinh ra và prompt đầu vào**.

# 4 Phương pháp nghiên cứu đã tìm hiểu

## 4.1 Reward Backpropagation(Align Prop))

### 4.1.1 Vấn đề và ý tưởng của AlignProp

Hơi đặc biệt một tí nhưng với AlignProp (một trong những kỹ thuật xuất hiện ở thời kì đầu 8/2023) thì nhóm tác giả không trực tiếp đi vào việc giải quyết bài toán tăng độ khớp ảnh và prompt như với Comat (11/2024) hay với RealignDiff (10/2024) nhưng là về bài toán cách tối ưu model bằng một hàm reward khả vi (có thể là Clip Score). Nhưng tôi vẫn đưa AlignProp vào bài bởi vì tăng độ khớp ảnh và prompt vẫn là một trong những mục tiêu tối ưu mà AlignProp quan tâm khi cố gắng cải thiện model Stable Diffusion để thỏa các tác vụ downstream thông thường.

Tuy nghiên lan truyền trực tiếp dẫn đến những hạn chế về bộ nhớ hoặc về model bị collapse. Để giải quyết vấn đề này, AlignProp đề xuất ý tưởng *Alignment by Backpropagation*, trong đó quá trình suy luận khử nhiễu của mô hình diffusion được xem như một chuỗi biến đổi khả vi. AlignProp tận dụng các hàm reward khả vi đánh giá trực tiếp chất lượng ảnh đầu ra (như độ khớp của ảnh với prompt), rồi lan truyền gradient ngược lại để fine-tune mô hình. Để tối ưu bộ nhớ, AlignProp chỉ cập nhật các tham số thích nghi nhẹ (LoRA) trong U-Net và sử dụng lan truyền ngược rút gọn qua một số bước khử nhiễu được chọn ngẫu nhiên, giúp mô hình cải thiện chất lượng và độ bám sát prompt mà vẫn đảm bảo tính ổn định khi huấn luyện.

### 4.1.2 Cách hiện thực AlignProp

Trước hết đây là ảnh minh họa sơ lược cách mà AlignProp hoạt động

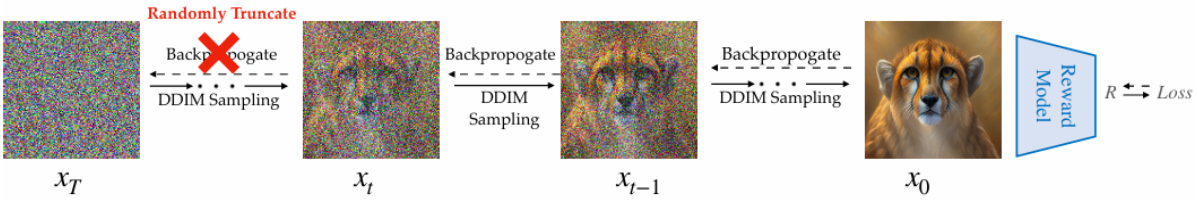


Hình 2: Chi tiết về cơ chế sẽ ở bên dưới.

AlignProp hiện thực hóa việc căn chỉnh mô hình diffusion với các mục tiêu hạ nguồn (ví dụ như độ rõ hình ảnh và mức độ phù hợp với prompt) bằng cách cho phép lan truyền gradient trực tiếp từ hàm đánh giá ảnh sinh ra ngược lại quá trình khử nhiễu. Thay vì xem diffusion chỉ là một quy trình sinh mẫu, AlignProp diễn giải nó như một chính sách khả vi có thể tối ưu hóa bằng backpropagation.

**(1) Mô hình hóa diffusion như một chính sách khả vi** Trong AlignProp, toàn bộ quá trình khử nhiễu được xem như một chính sách $\pi_\theta$ ánh xạ từ nhiễu ban đầu và prompt văn bản sang ảnh đầu ra. Cụ thể, với một prompt $c$ và nhiễu khởi tạo $z_T \sim \mathcal{N}(0, 1)$, chính sách diffusion sinh ảnh được biểu diễn là:

$$z_0 \sim \pi_\theta(\cdot \mid z_T, c), \tag{8}$$

trong đó $\theta$ là tham số của mô hình denoising U-Net.

Mục tiêu của AlignProp không còn là khớp phân phối dữ liệu huấn luyện, mà là tối đa hóa một hàm đánh giá downstream $R_\phi(z_0)$, phản ánh chất lượng ảnh sinh ra (ví dụ: ảnh rõ hơn, bám sát nội dung prompt hơn). Với tập prompt đầu vào $P$, hàm mất mát được định nghĩa là:

$$\mathcal{L}_{\text{align}}(\theta; P) = -\frac{1}{|P|} \sum_{c^i \in P} R_\phi\big(\pi_\theta(z_T, c^i)\big). \tag{9}$$

**Giải thích công thức:**

- $\pi_\theta(z_T, c_i)$: ảnh $z_0$ được sinh ra từ nhiễu $z_T$ và prompt $c^i$.
- $R_\phi(\cdot)$: hàm reward khả vi, đánh giá mức độ đáp ứng mục tiêu (độ rõ hình ảnh, mức độ phù hợp với prompt).

Gradient (đạo hàm) của hàm mất mát theo tham số mô hình có dạng:

$$\nabla_\theta \mathcal{L}_{\text{align}} = \frac{\partial \mathcal{L}_{\text{align}}}{\partial \theta} + \sum_{t=0}^{T} \frac{\partial \mathcal{L}_{\text{align}}}{\partial z_t} \frac{\partial z_t}{\partial \theta}. \tag{10}$$

Công thức trên cho thấy gradient phụ thuộc vào toàn bộ các trạng thái trung gian $z_t$ trong quá trình khử nhiễu, dẫn đến yêu cầu bộ nhớ rất lớn nếu triển khai trực tiếp.

**(2) Giảm chi phí bộ nhớ: LoRA và Gradient Checkpointing: Fine-tuning bằng LoRA.** Thay vì cập nhật trực tiếp toàn bộ tham số $\theta$ của U-Net, AlignProp chỉ huấn luyện các module Low-Rank Adaptation (LoRA). Mỗi lớp tuyến tính trong U-Net được sửa từ:

$$h = Wx \tag{11}$$

thành:

$$h = Wx + BAx, \tag{12}$$

trong đó $W \in \mathbb{R}^{m \times m}$là trọng số gốc, còn $A \in \mathbb{R}^{m \times k}$, $B \in \mathbb{R}^{k \times m}$ với $k \ll m$ là các tham số được huấn luyện.

Cách tiếp cận này giúp giảm số lượng tham số cần cập nhật xuống rất nhỏ giúp tiết kiệm cực kì nhiều bộ nhớ.

**Gradient Checkpointing.** Gradient checkpointing được sử dụng để giảm yêu cầu bộ nhớ khi lan truyền ngược qua chuỗi khử nhiễu dài. Thay vì lưu trữ toàn bộ các trạng thái trung gian, phương pháp này chỉ lưu một tập con các trạng thái trung gian. Nói đơn giản thì thay vì nhớ toàn bộ quá trình thì chỉ cần lưu một vài điểm còn lại thì khi lan truyền ngược tính lại.

Nhờ kết hợp LoRA và gradient checkpointing, AlignProp giúp việc lan truyền ngược xuyên suốt chuỗi diffusion trở nên khả thi.

**(3) Randomized Truncated Backpropagation Through Time** Tuy nhiên trong quá trình backpropagation thì gặp vấn đề là dễ dẫn đến hiện tượng over fitting và dễ bị collapse, khi mô hình học cách tối đa hóa reward bằng cách sinh ra một ảnh duy nhất cho mọi prompt. Để khắc phục, AlignProp sử dụng Randomized Truncated Backpropagation Through Time (TBTT).

Thay vì lan truyền gradient qua tất cả các bước, AlignProp chỉ backpropagation qua $K$ bước đầu tiên, với $K$ được chọn ngẫu nhiên, qua các thí nghiệm và quan sát thì khoảng K tốt nhất là:

$$K \sim Uniform(0, 50). \tag{13}$$

Gradient khi đó được xấp xỉ bởi:

$$\widehat{\nabla}_\theta \mathcal{L}_{\text{TBTT-align}} = \frac{\partial \mathcal{L}_{\text{align}}}{\partial \theta} + \sum_{k=0}^{K} \frac{\partial \mathcal{L}_{\text{align}}}{\partial z_k} \frac{\partial z_k}{\partial \theta}. \tag{14}$$

Cách làm này cho phép mô hình vừa học được sự căn chỉnh ngữ nghĩa ở các bước khử nhiễu sớm, vừa cải thiện chi tiết thị giác ở các bước muộn, đồng thời tránh hiện tượng sụp đổ mô hình.

## 4.2 RealignDiff

Ở phương pháp Align Prop trên thì việc giải quyết bài toán tăng độ khớp ảnh và prompt chưa phải là mục tiêu hàng đầu nhưng bắt đầu từ đây thì sẽ tập trung hơn vào đi vào giải quyết bài toán này.

### 4.2.1 Vấn đề và ý tưởng của RealignDiff

Vẫn là bài toán đó RealignDiff cũng là về việc các model sinh ảnh hiện nay dù đã tạo ảnh đẹp nhưng **bài toán tăng độ khớp ảnh và prompt** vẫn là một vấn đề còn tồn đọng nhức nhối, ảnh được sinh ra hoặc là thiếu đối tượng hoặc là ánh xạ sai thuộc tính và các mối quan hệ. Để giải quyết vấn đề này RealignDiff đề xuất một chiến lược tái căn chỉnh ngữ nghĩa từ thô đến tinh( *coarse-to-fine*).

Ở giai đoạn *coarse semantic re-alignment*, sử dụng một ”Phần thưởng chú thích”**(Caption Reward)** mới. Sử dụng mô hình BLIP-2 để tạo ra một bản mô tả chi tiết từ chính hình ảnh vừa sinh ra, sau đó tính toán điểm số tương đồng giữa bản mô tả đó và prompt gốc để tối ưu hóa mô hình từ góc nhìn tổng thể.

Sau đó, ở giai đoạn *fine semantic re-alignment*, sử dụng module tạo chú thích dày đặc cục bộ (Local Dense Caption Generation) và mô-đun điều chỉnh chú ý tái phân bổ trọng số (Reweighting Attention Modulation). Giai đoạn này tạo ra mask, chú thích chi tiết và điểm số xác suất cho từng đối tượng để tinh chỉnh các phần hình ảnh cục bộ. Trước khi đi vào chi tiết thì đây là sơ qua ảnh framework của RealignDiff

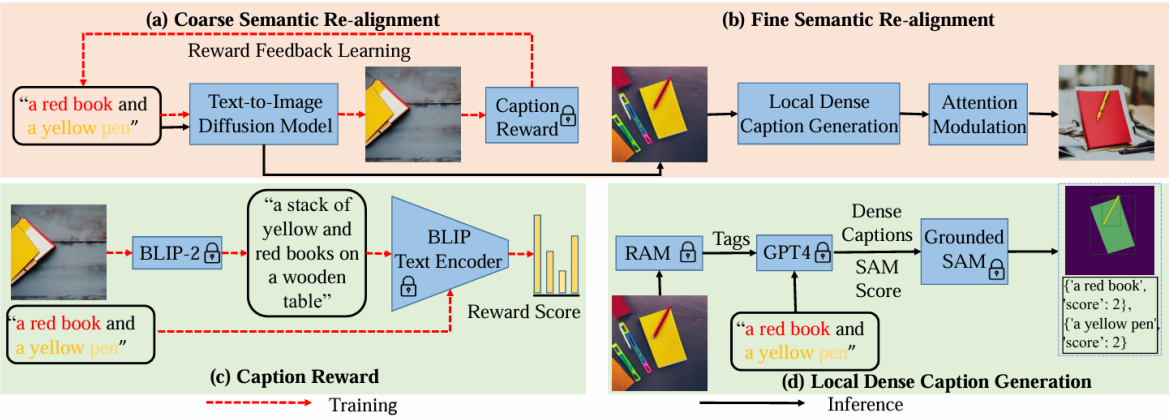


Hình 3: Ảnh minh họa framework của Realign Diff.

### 4.2.2 Căn chỉnh thô (Coarse Semantic Re-alignment)

Để giải quyết vấn đề thiếu đối tượng toàn cục, RealignDiff đề xuất phương pháp căn chỉnh thô nhằm đảm bảo các đối tượng chính được mô tả trong prompt sẽ xuất hiện trong ảnh, đảm bảo sự khớp ngữ nghĩa giữa ảnh và input prompt ở mức độ toàn cục.

**Caption Reward.** Ý tưởng cốt lõi của căn chỉnh thô là sử dụng một mô hình I2T mạnh (BLIP-2) để đánh giá nội dung của ảnh sinh ra. Cụ thể, với một ảnh được sinh bởi mô hình Stable Diffusion từ prompt văn bản $t_p$, RealignDiff sử dụng BLIP-2 để tạo ra một caption tương ứng $t_g$ mô tả nội dung ảnh đó. Sau đó, mức độ phù hợp giữa caption sinh ra và prompt ban đầu được đo bằng công thức đo độ tương đồng cosine trong không gian embedding văn bản.

Ưu điểm của cosine prompt–caption similarity là tập trung mạnh vào nội dung ngữ nghĩa ở mức khái niệm và mối quan hệ, đồng thời ít bị ảnh hưởng bởi các đặc trưng thị giác không liên quan trực tiếp đến prompt so với các chỉ số dựa trên CLIP image–text similarity. Tuy nhiên, phương pháp này phụ thuộc đáng kể vào chất lượng của mô hình sinh caption và có thể bỏ sót các sai lệch cục bộ tinh vi về thuộc tính hoặc bố cục, những lỗi mà các đánh giá dựa trực tiếp trên ảnh đôi khi phản ánh tốt hơn.

Caption reward được định nghĩa như sau:

$$R_{\text{cap}} = \frac{f_{\text{enc}}(t_g) \cdot f_{\text{enc}}(t_p)}{\|f_{\text{enc}}(t_g)\| \, \|f_{\text{enc}}(t_p)\|}, \tag{15}$$

trong đó:

- $t_g$ là caption được sinh ra từ ảnh bằng mô hình BLIP-2.
- $t_p$ là prompt văn bản đầu vào của mô hình Stable Diffusion.
- $f_{\text{enc}}(\cdot)$ là bộ mã hóa văn bản được huấn luyện sẵn (text encoder của BLIP-2), dùng để ánh xạ caption và prompt vào cùng một không gian embedding.
- Tích vô hướng ở tử số đo mức độ tương đồng ngữ nghĩa giữa caption sinh ra và prompt.
- Mẫu số dùng để chuẩn hóa embedding, đảm bảo giá trị $R_{\text{cap}}$ nằm trong khoảng $[-1, 1]$.

Nói một cách đơn giản thì giá trị $R_{\text{cap}}$ càng cao thì nội dung ảnh sinh ra càng khớp với prompt đầu vào.

**Reward Feedback Learning.** Dựa trên caption reward, RealignDiff sử dụng cơ chế *Reward Feedback Learning (ReFL)* để fine-tuning mô hình Stable Diffusion. Thay vì chỉ tối ưu hàm mất mát khử nhiễu truyền thống, ReFL cho phép mô hình nhận phản hồi trực tiếp từ chất lượng ngữ nghĩa của ảnh sinh ra.

Trong quá trình huấn luyện, một bước nhiễu trung gian $z_t$ được chọn ngẫu nhiên. Từ $z_t$, mô hình không thực hiện chuỗi khử nhiễu đầy đủ mà trực tiếp dự đoán ảnh $z_0'$ để tính caption reward. Cách làm này giúp tránh việc lan truyền gradient không ổn định khi chỉ dựa vào bước khử nhiễu cuối cùng (vì bước cuối đã gần như hoàn thành, các thay đổi nhỏ sẽ ảnh hưởng rất lớn đến điểm thưởng khiến mô hình khó hội tụ) và thường thì ( $t \geq 30$) đủ để mô hình Blip-2 nhận diện được trả về kết quả hiệu quả.

Hàm mất mát tổng trong giai đoạn căn chỉnh thô được xây dựng như sau:

$$\mathcal{L}_{\text{total}} = \lambda\, \mathcal{L}_{\text{reward}} + \mathcal{L}_{\text{pre}}, \tag{16}$$

trong đó:

$$\mathcal{L}_{\text{reward}} = \phi\big(R_{\text{cap}}(t_p, g_\theta(t_p))\big), \tag{17}$$

và

$$\mathcal{L}_{\text{pre}} = \mathbb{E}_{z_0,\epsilon,t}\big\|\epsilon - \epsilon_\theta(z_t, t_p, t)\big\|^2. \tag{18}$$

Ý nghĩa các thành phần:

- $g_\theta(t_p)$ là ảnh được sinh ra từ prompt $t_p$ bởi mô hình khuếch tán với tham số $\theta$.
- $\phi(\cdot)$ là hàm ReLU, giúp loại bỏ các phản hồi âm và ổn định quá trình huấn luyện.
- $\mathcal{L}_{\text{reward}}$ khuyến khích mô hình sinh ảnh có caption phù hợp hơn với prompt.
- $\mathcal{L}_{\text{pre}}$ là hàm mất mát khử nhiễu gốc của Stable Diffusion, để tránh hiện tượng overfitting và suy giảm chất lượng sinh ảnh.
- $\lambda$ là hệ số cân bằng giữa mục tiêu căn chỉnh ngữ nghĩa và việc duy trì khả năng sinh ảnh ban đầu.

Thông qua cơ chế căn chỉnh thô này, RealignDiff đảm bảo rằng ảnh sinh ra không chỉ đẹp về mặt thị giác mà còn phản ánh đúng các nội dung chính được mô tả trong prompt, tạo nền tảng vững chắc cho giai đoạn căn chỉnh tinh ở bước tiếp theo.

### 4.2.3 Căn chỉnh tinh (Fine Semantic Re-alignment)

Tiếp theo đến với căn chỉnh tinh, đây sẽ là giai đoạn giúp chúng ta xử lý các sai lệch chi tiết hơn ở mức local, mục tiêu cuối cùng là đảm bảo thuộc tính và mối quan hệ giữa các đối tượng được thể hiện chính xác.

Giai đoạn này bao gồm hai thành phần chính: *Local Dense Caption Generation* và *Re-weighting Attention Modulation*.

**Local Dense Caption Generation.** Thành phần Local Dense Caption tập trung phân tích ảnh sinh ra ở mức đối tượng riêng lẻ, thay vì đánh giá toàn ảnh như caption reward. Trước hết, RealignDiff sử dụng mô hình nhận dạng đối tượng tổng quát RAM (Recognize Anything Model) để tạo nhãn cho các đối tượng xuất hiện trong ảnh. Từ các nhãn đối tượng này kết hợp với prompt ban đầu, LLM lớn với khả năng suy luận về ngữ nghĩa tốt (ví dụ như GPT-4 được dùng trong bài báo) được sử dụng để đánh giá mức độ hợp lý của từng đối tượng trong bối cảnh mô tả.

Với mỗi đối tượng có nhãn $c$, GPT-4 gán một điểm tin cậy $s_i$ phản ánh khả năng đối tượng đó có thể xuất hiện trong ảnh:

$$s_i = \begin{cases} 2, & \text{nếu đối tượng chắc chắn xuất hiện trong ngữ cảnh,} \\ 0.5, & \text{nếu đối tượng có thể xuất hiện,} \\ 0, & \text{nếu đối tượng khó hoặc không nên xuất hiện.} \end{cases} \tag{19}$$

Trong đó:

- $s_i$ là điểm đánh giá mức độ phù hợp ngữ nghĩa của đối tượng thứ $i$.

Sau khi có danh sách đối tượng, điểm tin cậy $\{s_i\}$ và mô tả chi tiết cục bộ $\{l_i\}$, RealignDiff tiếp tục sử dụng mô hình Grounded-SAM để xác định vùng không gian tương ứng (mask) $\{m_i\}$ của từng đối tượng trong ảnh. Thông tin này đóng vai trò nền tảng cho việc điều chỉnh attention ở bước tiếp theo.

**Reweighting Attention Modulation.** Mục tiêu của cơ chế reweighting attention là điều chỉnh mức độ ảnh hưởng của từng token văn bản lên các vùng không gian cụ thể trong ảnh, dựa trên độ tin cậy của đối tượng và vị trí của nó.

Trong mô hình khuếch tán, bản đồ attention gốc được tính như sau:

$$A = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right), \tag{20}$$

RealignDiff điều chỉnh bản đồ attention này bằng cách bổ sung một ma trận điều chế $M$, tạo thành attention mới:

$$A' = \text{softmax}\left(\frac{QK^T + S \odot M}{\sqrt{d}}\right), \tag{21}$$

trong đó $M$ được xác định như sau:

$$M = \lambda_t \cdot R \odot M_{\text{pos}} \odot (1 - B) - \lambda_t \cdot (1 - R) \odot M_{\text{neg}} \odot (1 - B). \tag{22}$$

Ý nghĩa các thành phần:

- $\odot$ là phép nhân từng phần tử (Hadamard product).
- $\lambda_t$ là hệ số phụ thuộc vào timestep $t$, điều chỉnh cường độ tác động.
- $S$ là ma trận điểm re-weighting, được xây dựng từ điểm tin cậy $s_i$ và mask $m_i$.
- $R$ là vector nhị phân thể hiện token văn bản nào đang được kích hoạt.
- $B = QK^T$ biểu diễn mức tương đồng giữa đặc trưng ảnh và văn bản.

Ma trận $S_i$ cho mỗi đối tượng $i$ được xây dựng theo quy tắc:

$$S_{ijk} = \begin{cases} s_i, & \text{nếu } m_{ijk} > 0, \\ 1, & \text{nếu } m_{ijk} \leq 0, \end{cases} \tag{23}$$

trong đó:

- $(j, k)$ là tọa độ pixel trong mask.

- Giá trị $s_i$ làm tăng hoặc giảm ảnh hưởng của token tương ứng lên vùng đối tượng.

Ngoài ra, hai thành phần $M_{\text{pos}}$ và $M_{\text{neg}}$ được định nghĩa như sau:

$$M_{\text{pos}} = \max(QK^T) - QK^T, \quad M_{\text{neg}} = QK^T - \min(QK^T), \tag{24}$$

Đây chỉ đơn thuần là công thức hướng sự chú ý sang nơi khác để tránh việc bỏ sót các pixel chưa được quan tâm và ngược lại các vùng được quan tâm nhiều thì chuyển sang các vùng khác.

Thông qua sự kết hợp giữa căn chỉnh tinh và thô thì RealginDiff đã giúp có thêm 1 cái nhìn mới về cách giải quyết bài toán tăng độ khớp ảnh và prompt này.

## 4.3 CoMat

### 4.3.1 Vấn đề và ý tưởng của Comat

Theo Comat vấn đề đối với các mô hình Stable Diffusion model hiện nay là tại vì mô hình (cụ thể hơn là lớp cross-attention của Unet) không thể hiện đầy đủ và chính xác các hình ảnh đối với mô tả. Nguyên nhân được Comat chia ra làm 2 loại :

- **Concept Ignorance**: Sự bỏ sót một số khái niệm từ prompt đầu vào của SD.
- **Concept Mismapping**: Sự gán sai thuộc tính của các đối tượng so với mô tả từ prompt đầu vào.

Giải pháp mà Comat đề ra là **Concept Activation** được đề xuất nhằm giải quyết **Concept Ignorance**. Khác với việc chỉ coi gợi ý văn bản như một điều kiện bổ sung , cách tiếp cận của comat tích hợp việc sử dụng một mô hình I2T mạnh mẽ khác như một giám sát viên trong quá trình huấn luyện. Nhờ khả năng mạnh mẽ của mô hình I2T trong việc phát hiện khái niệm, bất cứ khi nào một khái niệm nào đó bị thiếu trong hình ảnh sinh ra, diffusion model sẽ được điều chỉnh để bổ sung nó vào quá trình tạo ảnh. Sự hướng dẫn này buộc mô hình khuếch tán phải xem xét lại các điều kiện bị bỏ qua và chú ý nhiều hơn đến chúng. Ví dụ minh họa trong Hình bên dưới cho thấy khái niệm bị bỏ sót trong ảnh (ví dụ: chiếc áo choàng) có giá trị kích hoạt chú ý thấp. Sau khi áp dụng phương pháp của Comat, có thể quan sát thấy sự gia tăng kích hoạt chú ý đối với từng khái niệm chính, góp phần tạo ra hình ảnh phù hợp hơn.

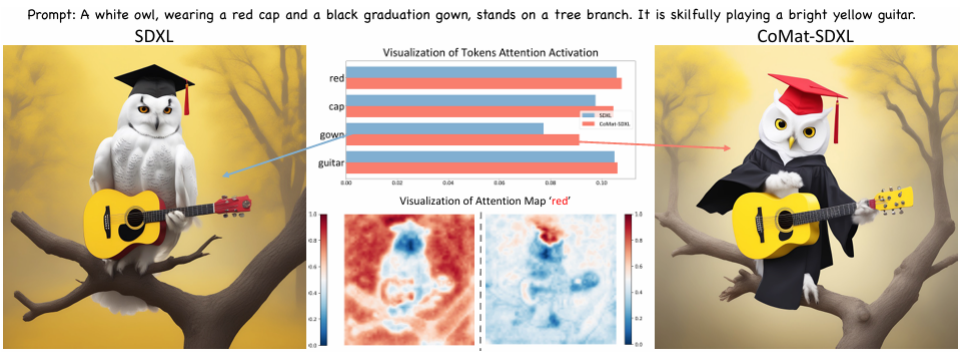


Hình 4: Có thể thấy không chỉ giúp token ”gown”được chú ý và xuất hiện thì attribute ”red”cũng được map đúng với vùng của thực thể ”cap”hơn.

Đối với **Concept Mismapping**, chúng tôi nhận thấy nó đặc biệt phổ biến ở các thuộc tính của đối tượng. Do đó, **Attribute Concentration** được đưa ra nhằm phục vụ cho cả ánh xạ dương và âm. Nói cách khác, Comat kiểm soát rất chặt chẽ đảm bảo các token thuộc tính chỉ xuất hiện ở đúng vùng của thực thể mà nó thuộc về.

Nhờ đó Comat đảm bảo cả cấu trúc tổng thể lẫn chi tiết cục bộ đều xuất hiện đúng và đầy đủ.

### 4.3.2 Concept Activation

Trước khi đi vào chi tiết hơn thì đây là một overview về Comat.

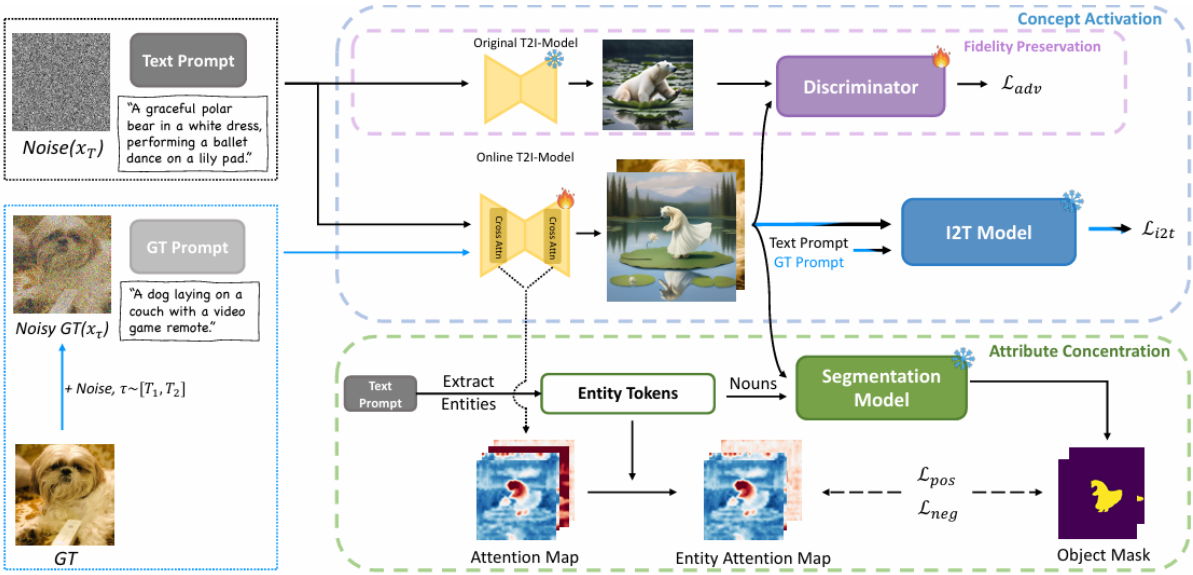


Hình 5: T2I Model tạo 1 ảnh dựa trên prompt rồi sàu đó ảnh được đưa qua Concept Activation và Attribute Concentration để tính loss chung.

Ý tưởng chính của Concept Activation là sử dụng một mô hình I2T đã được huấn luyện sẵn để đánh giá ảnh đã được sinh ra so với nội dung của prompt. Các mô hình I2T được train với task nhận diện ảnh rất tốt, do đó chúng có khả năng phát hiện hiệu quả các khái niệm bị thiếu hoặc thể hiện không rõ ràng trong ảnh.

Cụ thể, với một prompt văn bản

$$P = \{w_1, w_2, \ldots, w_L\},$$

mô hình diffusion sinh ra một ảnh $I$ sau quá trình khử nhiễu. Ảnh này sau đó được đưa vào mô hình I2T ($C$) để tính độ khớp ngữ nghĩa của ảnh so với input prompt dưới dạng 1 hàm log-likelihood. Khi nào mà prompt được I2T sinh ra không giống với input prompt thì sẽ làm cho hàm loss ngày càng lớn, mục tiêu train là tối thiểu hóa hàm loss.
Hàm mất mát Concept Activation được định nghĩa như sau:

$$\mathcal{L}_{i2t} = -\log\big(p_C(P \mid I(P;\epsilon_\theta))\big) = -\sum_{i=1}^{L} \log\big(p_C(w_i \mid I, w_{1:i-1})\big). \tag{25}$$

Trong đó, $p_C(....)$ biểu diễn xác suất mà mô hình I2T sinh ra toàn bộ prompt $P$ dựa trên ảnh $I$, còn $p_C(w_i \mid I, w_{1:i-1})$ là xác suất sinh token $w_i$ tại vị trí thứ $i$ khi đã biết các token trước đó (nghĩa là khi đã có ảnh và các token trước thì xác suất sinh ra token đúng là công thức).

Hay nói một cách dễ hiểu hơn thì nếu một khái niệm trong prompt không xuất hiện trong ảnh sinh, mô hình I2T sẽ nhận diện dẫn đến giá trị loss lớn. Khi lan truyền gradient của hàm mất mát này ngược về mô hình diffusion, các khái niệm bị bỏ sót sẽ buộc buộc mô hình phải tăng mức độ chú ý dành cho chúng trong quá trình sinh ảnh. Nhờ đó, Concept Activation trực tiếp giải quyết vấn đề Concept Ignorance.

Tuy nhiên, việc tối ưu hóa mô hình diffusion chỉ dựa trên giám sát từ I2T model có thể khiến mô hình học cách đánh lừa mô hình giám sát, dẫn đến suy giảm chất lượng ảnh sinh. Để hạn chế hiện tượng này, CoMat bổ sung hai cơ chế phụ trợ là **Fidelity Preservation** và **Mixed Latent Strategy**.

Fidelity Preservation được hiện thực dưới dạng một hàm mất mát đối kháng nhằm bảo toàn khả năng sinh ảnh ban đầu của mô hình diffusion. Với cùng một prompt, mô hình diffusion gốc sinh ra latent ảnh $\hat{z}_0$, trong khi mô hình đang fine-tune sinh ra latent $\hat{z}_0'$. Một discriminator $D_\phi$ được huấn luyện để phân biệt hai loại latent này. Hàm mất mát đối kháng được định nghĩa như sau:

$$\mathcal{L}_{adv} = \log\big(D_\phi(\hat{z}_0)\big) + \log\big(1 - D_\phi(\hat{z}_0')\big). \tag{26}$$

Trong quá trình huấn luyện, mô hình diffusion được tối ưu để tối thiểu hóa $\mathcal{L}_{adv}$, trong khi discriminator được huấn luyện để tối đa hóa khả năng phân biệt. Nói một cách dễ hiểu thì cách này là bắt mô hình thêm chi tiết bị bỏ sót vào ảnh gốc được tạo mà vẫn giữ các tính mĩ thuật và bố cục đẹp đẽ được tạo ra từ ảnh gốc thay vì bắt nó vẽ lại từ đầu khiến cho độ thẩm mĩ của ảnh bị phá vỡ.

Bên cạnh đó, CoMat còn sử dụng **Mixed Latent Strategy** để ổn định quá trình huấn luyện. Thay vì chỉ huấn luyện trên latent bắt đầu từ nhiễu thuần, phương pháp này kết hợp thêm các latent được tạo bằng cách thêm nhiễu vào ảnh thật tại một bước thời gian ngẫu nhiên trong chuỗi diffusion. Các latent này vốn đã khớp tốt với prompt, do đó cung cấp tín hiệu học đúng hướng, giúp cân bằng giữa việc cải thiện độ khớp ngữ nghĩa và việc bảo toàn chất lượng thị giác của ảnh sinh. Nói cách khác là giảm thiểu hành vi gian lận của các mô hình AI bằng các bài giải mẫu của các hình và ảnh thực tế.

### 4.3.3 Attribute Concentration

Tiếp theo là đến với **Attribute Concentration** một cách để giải quyết vấn đề về **Concept Mismapping**. Như đã giới thiệu, cho dù các đối tượng và thuộc tính đã xuất hiện đầy đủ nhưng việc ánh xạ đúng thuộc tính và đối tượng vẫn là một vấn đề nan giải, vì vậy Comat đã đề xuất giải pháp ràng buộc các token xuất hiện đúng vùng ảnh, đúng pixel qua 2 hàm loss âm và loss dương.

**Trích xuất thực thể và vùng đối tượng.** Đầu tiên từ prompt đầu vào, ta trích xuất tập các thực thể

$$\{e_1, e_2, \ldots, e_N\},$$

trong đó mỗi thực thể $e_i$ được biểu diễn bởi một cặp gồm danh từ và các thuộc tính đi kèm:

$$e_i = (n_i, a_i),$$

với $n_i$ là tập token danh từ và $a_i$ là tập token thuộc tính mô tả cho danh từ đó. Sau khi loại bỏ các danh từ trừu tượng hoặc không có vị trí rõ ràng trong ảnh, CoMat sử dụng mô hình phân đoạn ảnh mở (GROUNDED-SAM) để xác định vùng ảnh tương ứng với mỗi danh từ. Kết quả là các mặt nạ nhị phân

$$\{M_1, M_2, \ldots, M_N\},$$

trong đó $M_i(u, v) = 1$ nếu pixel $(u, v)$ thuộc về đối tượng $n_i$, và $M_i(u, v) = 0$ nếu không.

**Loss dương.** Mục tiêu của loss dương là khuyến khích các token của một thực thể (bao gồm danh từ và thuộc tính) tập trung attention vào đúng vùng ảnh của thực thể đó. Hàm mất mát tương ứng được định nghĩa như sau:

$$\mathcal{L}_{\text{pos}} = -\frac{1}{N} \sum_{i=1}^{N} \sum_{M^i_{u,v}=1} \left( \alpha \sum_{k \in n_i \cup a_i} \left( \frac{A^k_{u,v}}{\sum_{x,y} A^k_{x,y}} \right) + \beta \frac{\log(\sum_{k \in n_i \cup a_i} A^k_{u,v})}{|A|} \right) \tag{27}$$

Trong đó:

- $A^k_{u,v}$ là giá trị cross-attention của token $k$ tại vị trí pixel $(u, v)$
- $\sum_{x,y} A^k_{x,y}$ dùng để chuẩn hóa attention của token $k$ trên toàn ảnh, đảm bảo tổng attention của mỗi token là hằng số.
- $|A|$ là tổng số pixel trên bản đồ attention.
- Hệ số $\alpha$ và $\beta$ điều chỉnh mức độ ảnh hưởng của ràng buộc vùng (region-level constraint) và ràng buộc pixel (pixel-level constraint)

Thành phần thứ nhất (region-level) buộc mỗi token của thực thể phân bổ phần lớn attention của nó vào vùng ảnh tương ứng. Thành phần thứ hai (pixel-level) đảm bảo rằng mỗi pixel nằm trong vùng đối tượng chủ yếu chịu ảnh hưởng từ các token mô tả đúng thực thể đó.

**Loss âm.** Bên cạnh việc tăng attention ở vùng đúng, CoMat còn giảm attention của các token thực thể tại các vùng không liên quan. Ràng buộc này được mô hình hóa thông qua hàm mất mát:

$$\mathcal{L}_{\text{neg}} = -\frac{1}{N}\sum_{i=1}^{N}\sum_{M^i_{u,v}=0}\left(\underbrace{\alpha\sum_{k\in n_i\cup a_i}\left(\frac{-A^k_{u,v}}{\sum_{x,y}A^k_{x,y}}\right)}_{\text{region-level}}+\underbrace{\beta\frac{\log(1-\sum_{k\in n_i\cup a_i}A^k_{u,v})}{|A|}}_{\text{pixel-level}}\right) \tag{28}$$

Hàm mất mát này phạt các trường hợp mà token của một thực thể chú ý mạnh vào vùng ảnh không thuộc về thực thể đó, từ đó hạn chế việc thuộc tính bị gán nhầm sang các đối tượng khác hoặc nền ảnh. Trong trường hợp một thực thể không xuất hiện trong ảnh sinh ra, mặt nạ $M_i$ sẽ toàn bằng 0 và $\mathcal{L}_{neg}$ vẫn đóng vai trò ngăn không cho các token tương ứng kích hoạt ở bất kỳ pixel nào.

Đơn giản hơn thì 2 hàm loss này khuyến khích sự xuất hiện đúng và phạt sự xuất hiện sai của các cặp đối tượng và thuộc tính. Khi kết hợp với Concept Activation thì sẽ cải thiện đáng kể độ khớp ngữ nghĩa của model T2I.

**Hàm mất mát tổng của CoMat.** Cuối cùng, CoMat kết hợp loss từ mô hình I2T, loss bảo toàn chất lượng sinh ảnh và loss từ Attribute Concentration để xây dựng hàm mục tiêu tổng cho quá trình fine-tuning mô hình khuếch tán:

$$\mathcal{L} = \mathcal{L}_{i2t} + \mathcal{L}_{pos} + \mathcal{L}_{neg} + \lambda\mathcal{L}_{adv}, \tag{29}$$

trong đó:

- $\mathcal{L}_{i2t}$ là loss từ mô hình I2T, đóng vai trò giám sát việc mô hình sinh ảnh có phản ánh đầy đủ nội dung prompt hay không.
- $\mathcal{L}_{pos}$ và $\mathcal{L}_{neg}$ lần lượt khuyến khích ánh xạ thuộc tính đúng và hạn chế ánh xạ sai.
- $\mathcal{L}_{adv}$ là loss đối kháng từ module Fidelity Preservation, giúp bảo toàn chất lượng và phong cách sinh ảnh của mô hình ban đầu.
- $\lambda$ là hệ số cân bằng mức độ ảnh hưởng của loss đối kháng ($\lambda$ lớn thì ảnh đẹp nhưng không khớp và $\lambda$ nhỏ thì ảnh khớp nhưng dễ bị biến dạng).

# 5 So sánh và thảo luận

Do các phương pháp AlignProp, RealignDiff và CoMat được đề xuất ở những thời điểm khác nhau và tối ưu các mục tiêu không hoàn toàn trùng khớp, việc so sánh trực tiếp thông qua một chỉ số định lượng chung là không khả thi. Thay vào đó, chúng tôi thực hiện so sánh dựa trên các trục ngữ nghĩa và cơ chế can thiệp của từng phương pháp.

AlignProp thì giống như cách bạn thay đổi tư duy của cả 1 hệ thống, chính vì vậy cách này là triệt để nhất và có thể nói là tiềm năng nhất với một hàm reward đủ mạnh. RealignDiff có thể xem như là một người dẫn đường cho Stable Diffusion, đây là một giám sát viên đánh giá đầu ra của model. Còn Comat (theo tôi là thú vị nhất) thì là một người thắc mắc, Comat thắc mắc với model tại sao lại như vậy, buộc model phải giải thích hoặc xem lại quy trình.

**AlignProp Ưu điểm**

- Tối ưu trực tiếp theo hàm reward khả vi, không bị giới hạn bởi loss khuếch tán truyền thống.
- Có tính tổng quát cao, dễ mở rộng sang nhiều mục tiêu downstream (tăng độ khớp ảnh và prompt, thẩm mỹ, bố cục).
- Đặt nền tảng sớm cho hướng căn chỉnh diffusion bằng backpropagation thay vì reinforcement learning.

**Nhược điểm**

- Phụ thuộc mạnh vào chất lượng của hàm reward; reward không hoàn hảo dễ gây over-optimization.
- Dễ xảy ra hiện tượng collapse nếu backpropagation qua toàn bộ chuỗi khử nhiễu.
- Chi phí tính toán và bộ nhớ cao, cần kỹ thuật bổ trợ (LoRA, gradient checkpointing, TBTT).

**RealignDiff Ưu điểm**

- Chiến lược coarse-to-fine giúp cải thiện độ khớp ảnh và prompt cả ở mức toàn cục và cục bộ.
- Không can thiệp sâu vào kiến trúc diffusion, dễ tích hợp với các mô hình có sẵn.
- Đạt cân bằng tốt giữa độ khớp ngữ nghĩa và chất lượng thị giác của ảnh sinh.

**Nhược điểm**

- Phụ thuộc vào chất lượng của mô hình trung gian (BLIP-2, LLM).
- Nếu phản hồi ngữ nghĩa trung gian sai, quá trình căn chỉnh tinh có thể bị ảnh hưởng tiêu cực.
- Khả năng kiểm soát chi tiết bên trong cơ chế sinh ảnh còn hạn chế.

**CoMat Ưu điểm**

- Can thiệp trực tiếp vào tầng cross-attention, kiểm soát chính xác việc ánh xạ khái niệm và thuộc tính.
- Giải quyết hiệu quả cả Concept Ignorance và Concept Mismapping.
- Cho khả năng kiểm soát chi tiết cục bộ và tính diễn giải cao.

**Nhược điểm**

- Phụ thuộc vào mô hình phân đoạn và I2T, bị giới hạn bởi năng lực của các mô hình này.
- Khó xử lý các trường hợp nhiều đối tượng cùng loại.
- Thời gian huấn luyện dài do yêu cầu thực hiện đầy đủ quá trình suy luận diffusion.

## 5.1 Kết Quả Trực Quan

Đây là ảnh sơ lược về kết quả của cả 3 phương pháp

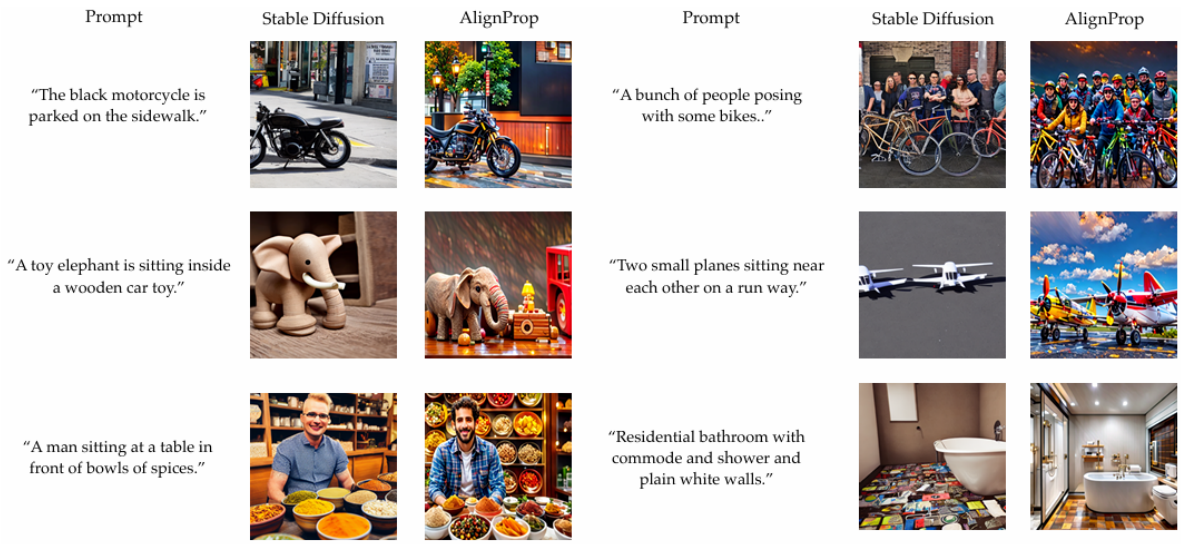


Hình 6: Align Prop.

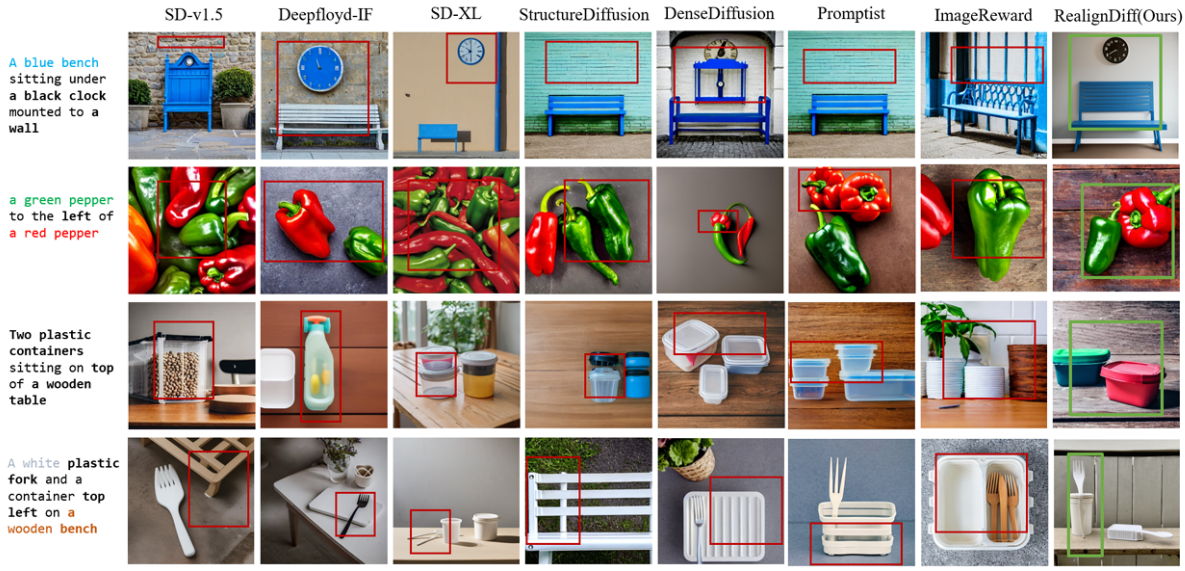


Hình 7: Realign Diff

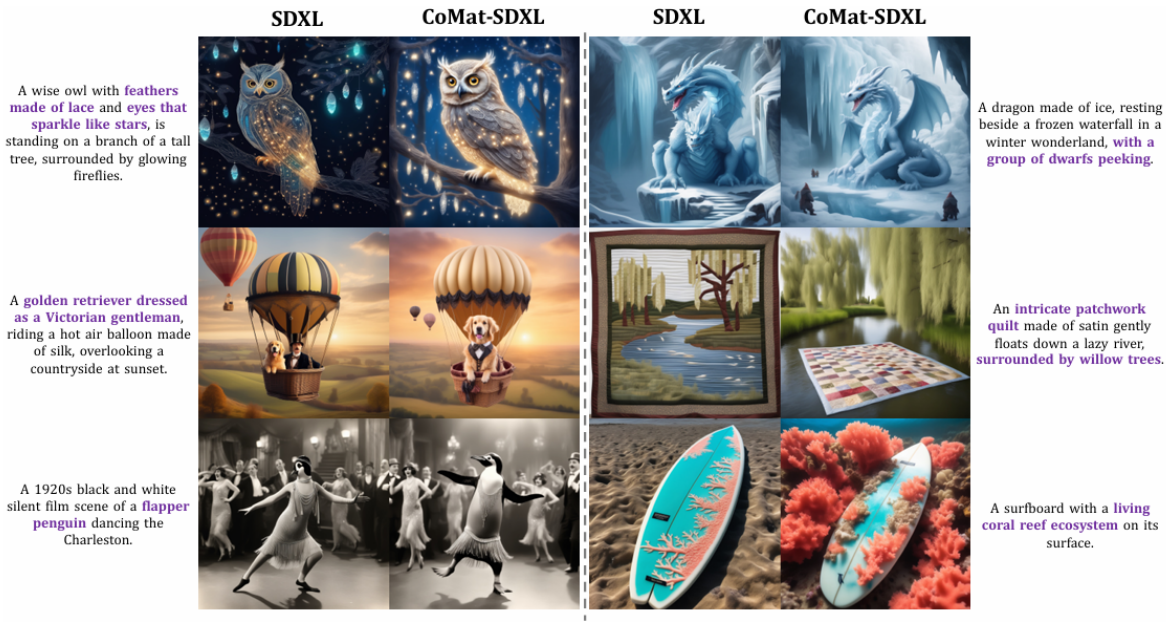


Hình 8: Comat

# 6 Hướng đi đề xuất từ 3 giải pháp trên

Mặc dù thiếu đi kinh nghiệm thực hành cũng như các kiến thức chuyên sâu nhưng qua sự nghiên cứu về 3 hướng tiếp cận này, có thể thấy rằng 3 cách này là những mảnh ghép riêng lẻ và có thể được bổ trợ cho nhau. Sau khi nghiên cứu tôi có một giải pháp được nghĩ ra rằng chúng ta có thể kết hợp cả 3 phương pháp.
Một hướng tiếp cận khả thi là áp dụng ba phương pháp theo trình tự huấn luyện, thay vì đồng thời ngay từ đầu:

- Giai đoạn 1 – Align Prop: Sử dụng AlignProp với các hàm reward đơn giản (có thể là hàm cosine similarity của algin prop) để điều chỉnh phân phối sinh ảnh chung, giúp mô hình bám sát prompt hơn ở mức tổng thể.

- Giai đoạn 2 – Realign Diff: Áp dụng RealignDiff để sửa các sai lệch còn tồn tại sau giai đoạn 1, đặc biệt là thiếu đối tượng, sai quan hệ và sai ngữ cảnh. Chiến lược coarse-to-fine giúp ổn định mô hình trước khi can thiệp sâu hơn. Dùng cách này có thể tạo ra được tập dữ liệu đầu vào cực chất lượng cho giai đoạn 3.

- Giai đoạn 3 – Comat: Fine-tuning cuối bằng CoMat nhằm xử lý các lỗi chi tiết như gán nhầm thuộc tính, sai vị trí, hoặc bỏ sót khái niệm hiếm. Ở giai đoạn này, cross-attention đã tương đối ổn định, nên việc ràng buộc attention trở nên hiệu quả và ít phá vỡ chất lượng thị giác.

Cách huấn luyện theo lộ trình này giúp tránh hiện tượng mô hình bị quá tải ràng buộc ngay từ đầu, đồng thời tận dụng thế mạnh của từng phương pháp ở đúng thời điểm (mô hình sau kế thừa trọng số của mô hình trước). Tuy nhiên một vấn đề dễ để ý thấy là chi phí tính toán cũng như thời gian train khi phải trải qua từng giai đoạn như này là khá lớn cũng như việc mô hình có thể quên đi những gì được huấn luyện ở giai đoạn trước. Nhưng vì hạn chế về chuyên môn nên đây có thể xem như là phương pháp dễ hiểu nhất và hợp lý nhất mà tôi có thể đề xuất.

# 7 Kết luận

Phần trên là toàn bộ những nghiên cứu và hướng giải quyết mà tôi đề xuất để giải quyết bài toán tăng độ khớp giữa input prompt và ảnh đầu ra mà tôi đã nghiên cứu. Qua đồ án lần này tôi đã có thêm cái nhìn tổng quát hoặc có thể nói là khá vững về mảng text to image này. Bài toán cải thiện độ khớp giữa hình ảnh và input prompt cũng là một trong những bài toán thực tế nhưng chưa có quá nhiều sự quan tâm nên tôi đánh giá bài báo này cũng khá hữu ích cho tương lai nếu có ý định tìm hiểu sâu hơn và hiện thực. Và cuối cùng, em cảm ơn thầy đã quan tâm và hướng dẫn em trong đồ án lần này.